Reconocimiento de Patrones

Examen intermedio C

Problemas 1 y 2

Nombre	Rogelio Peralta Morales
Expediente	222214735
Parámetros	$a = 5$, $b = 3$, semilla $= 222214735$

Problema 1. Equidad imposible

Desarrollo teórico

En cada inciso, las probabilidades se calculan dentro de un grupo g, salvo que se indique otra cosa. Supongo que $0 < p < 1$: en el grupo hay clientes que pagan y clientes que no pagan.

(a) Una identidad

Supongo además que $\mathrm{PPV} > 0$, para que la división entre PPV tenga sentido. La regla del producto dice que $\mathbb{P}(C, D) = \mathbb{P}(C \mid D)\,\mathbb{P}(D)$ para eventos C y D con $\mathbb{P}(D) > 0$, y la aplico en los dos órdenes posibles.

Primero escribo la probabilidad de un falso positivo. Condicionando en $Y = 0$ se obtiene FPR, y condicionando en $\hat{Y} = 1$ se obtiene el complemento de PPV, porque $\mathbb{P}(Y = 0 \mid \hat{Y} = 1) = 1 - \mathrm{PPV}$ (el complemento se aplica al evento de la izquierda de la barra, con la condición fija):

$$\mathbb{P}(\hat{Y} = 1, Y = 0) = \mathbb{P}(\hat{Y} = 1 \mid Y = 0)\,\mathbb{P}(Y = 0) = \mathrm{FPR}\,(1-p), \qquad \mathbb{P}(\hat{Y} = 1, Y = 0) = \mathbb{P}(Y = 0 \mid \hat{Y} = 1)\,\mathbb{P}(\hat{Y} = 1) = \tag{1}$$

Hago lo mismo con un verdadero positivo. Como $\mathbb{P}(\hat{Y} = 1 \mid Y = 1) = 1 - \mathbb{P}(\hat{Y} = 0 \mid Y = 1) = 1 - \mathrm{FNR}$,

$$\mathbb{P}(\hat{Y} = 1, Y = 1) = (1 - \mathrm{FNR})\,p, \qquad \mathbb{P}(\hat{Y} = 1, Y = 1) = \mathrm{PPV}\,\mathbb{P}(\hat{Y} = 1). \tag{2}$$

De la segunda igualdad de (2) despejo $\mathbb{P}(\hat{Y} = 1) = (1 - \mathrm{FNR})\,p/\mathrm{PPV}$. Al sustituirlo en la segunda igualdad de (1) y compararla con la primera queda

$$\mathrm{FPR}\,(1 - p) = (1 - \mathrm{PPV})\,\frac{(1 - \mathrm{FNR})\,p}{\mathrm{PPV}}. \tag{3}$$

Como $1 - p > 0$, puedo dividir entre $1 - p$, y al reordenar los factores obtengo la identidad:

$$\mathrm{FPR} = \frac{p}{1-p} \cdot \frac{1 - \mathrm{PPV}}{\mathrm{PPV}} \cdot (1 - \mathrm{FNR}). \tag{4}$$

■

(b) La imposibilidad

Cálculos. Con $\mathrm{PPV} = 0.5$, el factor $(1 - \mathrm{PPV})/\mathrm{PPV}$ vale 1. Con $\mathrm{FNR} = 0.3$, la identidad (4) da

$$\mathrm{FPR}_A = \frac{0.30}{0.70} \cdot 1 \cdot 0.7 = 0.30, \qquad \mathrm{FPR}_B = \frac{0.20}{0.80} \cdot 1 \cdot 0.7 = 0.175.$$

Para que los dos grupos tengan la misma FNR y la misma FPR, mantengo el grupo A como está y busco $\text{PPV}_B = x$ tal que $\text{FPR}_B = 0.30$ con $\text{FNR} = 0.3$:

$$0.30 = \frac{0.20}{0.80} \cdot \frac{1-x}{x} \cdot 0.7 = 0.175\,\frac{1-x}{x} \implies \frac{1-x}{x} = \frac{12}{7} \implies 7(1-x) = 12x \implies x = \frac{7}{19} \approx 0.368.$$

Los errores se igualan solo si la PPV deja de ser igual: 0.5 en A y cerca de 0.368 en B.

Proposición. *Sean $p_A \neq p_B$, con ambas en $(0,1)$. Si un clasificador tiene $0 < \text{PPV} < 1$ en los dos grupos, es decir, comete falsos positivos y también acierta algunos rechazos, entonces no puede tener a la vez la misma* PPV*, la misma* FPR *y la misma* FNR *en los dos grupos.*

Demostración. Supongamos que sí tiene las tres iguales y llamemos PPV, FPR y FNR a esos valores comunes. Como $\text{FPR}_A = \text{FPR}_B$, al aplicar (4) en cada grupo se obtiene

$$\frac{p_A}{1-p_A} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot (1-\text{FNR}) = \frac{p_B}{1-p_B} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot (1-\text{FNR}).$$

Los factores $\frac{1-\text{PPV}}{\text{PPV}}$ y $1-\text{FNR}$ aparecen en los dos lados y son distintos de cero, así que puedo cancelarlo. Queda:

$$\frac{p_A}{1-p_A} = \frac{p_B}{1-p_B}.$$

Como $1-p_A > 0$ y $1-p_B > 0$, multiplico en cruz:

$$p_A(1-p_B) = p_B(1-p_A) \implies p_A - p_A p_B = p_B - p_A p_B \implies p_A = p_B.$$

Esto contradice la hipótesis $p_A \neq p_B$. Por lo tanto, las tres métricas no pueden coincidir a la vez. □

Clasificador perfecto. Si el clasificador es perfecto, $\text{FPR} = \text{FNR} = 0$ y todos los rechazados son incumplidos, así que $\text{PPV} = 1$ en los dos grupos. Entonces $1 - \text{PPV} = 0$ y la identidad se reduce a $0 = 0$ para cualquier p. Las tres métricas coinciden aunque $p_A \neq p_B$, de modo que la imposibilidad no aplica.

Observación sobre el enunciado. La condición exacta de la demostración es $0 < \text{PPV} < 1$. Hay tres casos extremos que no son perfectos y quedan fuera de ella:

- **Sin falsos positivos:** si solo se rechaza a incumplidos y $\text{FNR} = 0.5$ en los dos grupos, entonces $\text{PPV} = 1$, $\text{FPR} = 0$ y las tres métricas coinciden.
- **Todos los rechazos son errores:** si solo se rechaza a quienes sí pagan, entonces $\text{PPV} = 0$ y $\text{FNR} = 1$, y la FPR puede ser igual. Aquí la identidad no aplica porque habría que dividir entre cero.
- **Nunca se rechaza:** la PPV no está definida.

Ninguno de estos casos sirve como regla de crédito, así que el resultado sigue valiendo para cualquier clasificador útil: si comete falsos positivos y acierta algunos rechazos, no puede igualar las tres métricas.

(c) Calibrado no quiere decir parejo

El promedio es la tasa. Como Y solo vale 0 o 1, $p_g = \mathbb{P}(Y = 1 \mid G = g) = \mathbb{E}[Y \mid G = g]$. Por (P1), condicionando todo a $G = g$,

$$p_g = \mathbb{E}\big[\,\mathbb{E}[Y \mid S, G = g] \;\big|\; G = g\big].$$

Por (P2), $\mathbb{E}[Y \mid S = s, G = g] = \mathbb{P}(Y = 1 \mid S = s, G = g) = s$ para todo s. Es decir, la esperanza interior es la propia variable S. Por lo tanto, $p_g = \mathbb{E}[S \mid G = g]$. ■

El ejemplo. Por el resultado anterior,

$$p_A = 0.6(0.2) + 0.4(0.8) = 0.44, \qquad p_B = 0.9(0.2) + 0.1(0.8) = 0.26.$$

Por calibración, de quienes tienen puntaje 0.8 no paga el 80 %, y de quienes tienen puntaje 0.2 no paga el 20 %. Multiplicando esas proporciones por el tamaño de cada puntaje (regla del producto) se obtienen las probabilidades conjuntas:

Grupo	$\mathbb{P}(S{=}0.8, Y{=}0)$	$\mathbb{P}(S{=}0.8, Y{=}1)$	$\mathbb{P}(S{=}0.2, Y{=}0)$	$\mathbb{P}(S{=}0.2, Y{=}1)$
A	0.08	0.32	0.48	0.12
B	0.02	0.08	0.72	0.18

Rechazar a quien tiene puntaje 0.8 significa que $\hat{Y} = 1$ equivale a $S = 0.8$. La FPR es la parte rechazada entre quienes pagan, y la FNR es la parte aceptada entre quienes no pagan:

$$\mathrm{FPR}_A = \frac{0.08}{0.56} = \frac{1}{7} \approx 0.143, \quad \mathrm{FNR}_A = \frac{0.12}{0.44} = \frac{3}{11} \approx 0.273, \quad \mathrm{FPR}_B = \frac{0.02}{0.74} = \frac{1}{37} \approx 0.027, \quad \mathrm{FNR}_B = \frac{0.18}{0.26} = \frac{9}{13} \approx$$

Además, $\mathrm{PPV}_A = \frac{0.32}{0.40} = 0.8$ y $\mathrm{PPV}_B = \frac{0.08}{0.10} = 0.8$.

¿Quién sale más perjudicado? Si importa la FPR, sale peor el grupo A: un cliente cumplido de A tiene más de cinco veces la probabilidad de ser rechazado que uno de B. Si importa la FNR, sale peor el grupo B: se escapa el 69 % de sus incumplidos, contra el 27 % en A. Ese error lo paga sobre todo el banco, aunque también afecta a un cliente que recibe un crédito que no podrá pagar.

El puntaje está calibrado y PPV = 0.8 en los dos grupos. Aun así, las tasas de error son muy distintas.

(d) El umbral del banco

Por calibración, un cliente con puntaje s no paga con probabilidad s y paga con probabilidad $1 - s$. Supongo que $G, L > 0$ y que no dar el crédito deja una ganancia de 0 (hipótesis que el enunciado no escribe y que se necesita para comparar las dos acciones). La ganancia esperada de darle el crédito es

$$(1 - s)\, G + s\, (-L) = G - (G + L)\, s.$$

Por lo tanto, conviene darlo si y solo si $G - (G + L)s > 0$. Como $G + L > 0$, esto equivale a

$$s < \frac{G}{G + L}.$$

Mi caso. Como $b = 3$, se tiene b mód $3 = 0$ y $L = 3G$. Entonces el umbral es

$$t = \frac{G}{G + 3G} = \frac{1}{4} = 0.25.$$

Por qué el mismo umbral es óptimo para todos. Sea $d_i \in \{0, 1\}$ la decisión para el cliente i, donde 1 significa dar el crédito. Por linealidad de la esperanza, la ganancia esperada total es

$$\sum_i d_i [G - (G + L)\, s_i].$$

La calibración en cada grupo garantiza que s_i es la probabilidad de no pagar sin importar el grupo, y por eso la expresión es la misma para todos. Cada término depende solo de la decisión de ese cliente, así que la suma se maximiza término por término: $d_i = 1$ si $s_i < G/(G + L)$ y $d_i = 0$ si $s_i > G/(G + L)$. Esta regla no depende del grupo. Un umbral distinto para algún grupo aceptaría clientes con ganancia esperada negativa o rechazaría clientes con ganancia esperada positiva, y no podría superarla.

Por qué eso da tasas de error distintas. Con un solo umbral t, el rechazo equivale a $S \geq t$ en los dos grupos. Pero por el inciso (c), $p_g = \mathbb{E}[S \mid G = g]$: si los grupos tienen tasas distintas, sus puntajes se distribuyen distinto. Por el inciso (b), si $p_A \neq p_B$, el clasificador no puede tener iguales PPV, FPR y FNR a la vez, salvo en los casos extremos ya descritos. Al menos una debe diferir.

Además, la calibración da $\text{PPV}_g = \mathbb{E}[S \mid S \geq t, G = g]$, que no fuerza la igualdad de los errores: en el ejemplo de (c), la PPV es igual y las diferencias aparecen en FPR y FNR. Maximizar la ganancia no iguala los errores, y por eso igualarlos tiene un costo para el banco.

(e) ¿Qué es justo aquí?

Mi decisión. Conservo la calibración como propiedad del puntaje, para que un mismo número signifique el mismo riesgo en los dos grupos. Pero el criterio de equidad para la decisión de crédito es la igualdad de FPR.

Quién paga cada error. Un falso positivo lo paga una persona que sí iba a pagar: pierde el crédito sin haber hecho nada malo y no tiene forma de demostrarlo. Un falso negativo lo paga sobre todo el banco, que pierde L, aunque también perjudica a quien recibe una deuda que no puede pagar. El banco ya se protege de ese segundo error, porque en mi caso le cuesta tres veces lo que gana con un buen cliente. Por eso su umbral es tan bajo como 0.25. Nadie protege al cliente cumplido en esa cuenta, y esa es la queja del problema.

Por qué no las otras definiciones.

- **Paridad demográfica:** pide la misma tasa de rechazo aunque el riesgo sea distinto. Por (c), $E[S \mid G = g] = p_g$, así que los grupos tienen distinta distribución de riesgo. Con $t = 0.25$, A rechaza al 40 % y B al 10 %. Para igualar las tasas habría que rechazar a clientes de B con $S = 0.2$, cuya ganancia esperada de aprobarlos es positiva, o aprobar a clientes de A con $S = 0.8$, cuya ganancia esperada es negativa. Es decir, se decidiría con criterios que no corresponden al riesgo de cada persona.
- **Paridad predictiva y calibración:** son el argumento del banco, y no responden a la queja. El ejemplo de (c) cumple las dos y aun así la FPR de A es más de cinco veces la de B.
- **Misma** FPR **y misma** FNR**:** es más exigente y, por el inciso (b), también sacrifica la PPV. No la exijo porque el daño de la FNR recae principalmente en el banco. Reconozco que no controlo la FNR, que quedará desigual entre grupos, y que una FNR alta también puede perjudicar al cliente que se sobreendeuda.

¿Son aceptables los umbrales distintos? Sí, con condiciones. Por el inciso (d), el umbral común es el óptimo para el banco, y como las distribuciones de puntaje difieren entre grupos, igualar la FPR exige umbrales distintos por grupo. Entonces dos personas con el mismo puntaje pueden recibir decisiones distintas. Eso tiene un costo real: renuncio a tratar igual a quienes tienen el mismo riesgo estimado, y el corte es abrupto entre alguien de 24 años y alguien de 25. Lo acepto porque lo que quiero repartir de forma pareja es la carga sobre los clientes cumplidos. Como atenuante, la edad no es un atributo fijo, pues todas las personas pasan por ese grupo, aunque reconozco que la decisión se toma una sola vez y un joven rechazado hoy no se compensa con lo que le ocurra después. Mi condición es que sea una política explícita, revisada y que respete la ley aplicable, no un ajuste oculto.

¿Debe el modelo usar el atributo como entrada? En mi caso, sí. Quitarlo no cumple por sí mismo ninguna de estas definiciones: la imposibilidad del inciso (b) depende de las tasas de cada grupo, no de lo que vio el modelo, y otras variables pueden contener el mismo dato. Además, aplicar umbrales por grupo exige conocer el grupo. Prefiero que el atributo sea visible y que su efecto se pueda medir. Lo que pierdo es que el modelo usa la edad directamente, lo que puede ser difícil de defender ante clientes o reguladores. La parte práctica pone a prueba esta decisión en el inciso (e), y la bitácora reporta el resultado.

Problema 2. Las 23:00 y la 01:00

Desarrollo teórico

(a) Dos maneras de medir

Las horas. Las 23:00 y las 01:00 corresponden a $\theta = 23\pi/12$ y $\theta' = \pi/12$. Entonces $|\theta - \theta'| = 11\pi/6$ y $2\pi - |\theta - \theta'| = \pi/6$, así que $d = \pi/6 \approx 0.524$. Ese arco equivale a 2 horas, mientras que la diferencia de los números es 22.

Los días. En los datos, `weekday` vale 6 el sábado y 1 el lunes. Con $P = 7$ se tiene $\theta = 12\pi/7$ y $\theta' = 2\pi/7$, de modo que $|\theta - \theta'| = 10\pi/7$ y $2\pi - |\theta - \theta'| = 4\pi/7$. Por lo tanto, $d = 4\pi/7 \approx 1.795$, que equivale a 2 días, mientras que la diferencia de los números es 5.

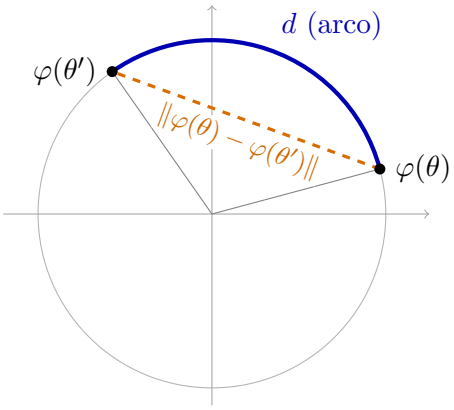
La identidad. Desarrollamos el cuadrado de la norma y usamos $\cos^2 x + \sin^2 x = 1$ en cada punto:

$$\begin{aligned}\|\varphi(\theta) - \varphi(\theta')\|^2 &= (\cos\theta - \cos\theta')^2 + (\sin\theta - \sin\theta')^2 \\ &= 2 - 2(\cos\theta\cos\theta' + \sin\theta\sin\theta') = 2 - 2\cos(\theta - \theta').\end{aligned}$$

La última igualdad es la fórmula del coseno de una diferencia. Además, d es igual a $|\theta - \theta'|$ o a $2\pi - |\theta - \theta'|$. Como el coseno es par y tiene periodo 2π, en ambos casos $\cos d = \cos(\theta - \theta')$, y queda

$$\|\varphi(\theta) - \varphi(\theta')\|^2 = 2 - 2\cos(\theta - \theta') = 2 - 2\cos d(\theta, \theta').$$

El dibujo. La figura muestra las dos medidas entre los mismos puntos: el arco d recorre el círculo y la cuerda lo cruza en línea recta.



Por qué ordenan igual. Usando $1 - \cos d = 2\sin^2(d/2)$ en la identidad, y como $\sin(d/2) \geq 0$ para $d \in [0, \pi]$, la cuerda mide

$$\|\varphi(\theta) - \varphi(\theta')\| = 2\sin(d/2).$$

La función $x \mapsto 2\sin(x/2)$ es estrictamente creciente en $[0, \pi]$, porque su derivada $\cos(x/2)$ es positiva en $[0, \pi)$. Por lo tanto, si un par tiene menor arco que otro, también tiene menor cuerda, y al revés. Las dos medidas ordenan igual a los pares, aunque no son proporcionales: casi coinciden para puntos cercanos, y en puntos opuestos el arco mide π y la cuerda 2.

(b) El seno y el coseno, otra vez

Usar $\varphi(\theta)$ con un kernel gaussiano significa usar $\exp\big(-\|\varphi(\theta)-\varphi(\theta')\|^2/2\sigma^2\big)$. Por el inciso (a),

$$\exp\left(-\frac{2-2\cos(\theta-\theta')}{2\sigma^2}\right) = e^{-1/\sigma^2}\,\exp\left(\frac{\cos(\theta-\theta')}{\sigma^2}\right).$$

Es decir, la receta equivale a k_κ con $\boxed{\kappa = 1/\sigma^2}$, multiplicado por la constante $e^{-\kappa}$. Multiplicar por una constante positiva no altera el problema de ser kernel, por (P1).

El coseno es un kernel porque tiene función de características φ:

$$\varphi(\theta)^\top \varphi(\theta') = \cos\theta\cos\theta' + \sin\theta\sin\theta' = \cos(\theta-\theta').$$

Para k_κ, escribimos la serie de Taylor de la exponencial:

$$k_\kappa(\theta,\theta') = \sum_{m=0}^{\infty} \frac{\kappa^m}{m!}\cos^m(\theta-\theta').$$

Cada potencia $\cos^m(\theta-\theta')$ con $m \geq 1$ es un kernel, porque es un producto de kernels. El término $m=0$ es la constante 1, que es un kernel con función de características $\phi(\theta)=1$. Cada coeficiente $\kappa^m/m!$ es positivo si $\kappa > 0$, así que cada suma parcial es una suma de kernels multiplicados por constantes positivas y, por (P1), es un kernel. Finalmente, la serie converge en cada punto y k_κ es su límite puntual, de modo que también es un kernel por (P1).

(c) Por qué funciona el criterio de Fourier

Supongamos que $a_n \geq 0$ para toda $n \geq 0$. La sugerencia es la identidad $\cos(n\theta - n\theta') = \cos n\theta\cos n\theta' + \sin n\theta \sin n\theta'$. Esto dice que el término n-ésimo es un producto punto. Para $n \geq 1$ definimos

$$\phi_n(\theta) = \sqrt{a_n}\,\big(\cos n\theta,\ \sin n\theta\big).$$

Entonces

$$\phi_n(\theta)^\top \phi_n(\theta') = a_n\big(\cos n\theta\cos n\theta' + \sin n\theta\sin n\theta'\big) = a_n\cos\big(n(\theta-\theta')\big).$$

La raíz existe precisamente porque $a_n \geq 0$, así que cada término $a_n\cos(n(\theta-\theta'))$ es un kernel. El término constante a_0 también lo es, con $\phi_0(\theta) = \sqrt{a_0}$.

Por (P1), cada suma parcial $S_M(\theta,\theta') = a_0 + \sum_{n=1}^{M} a_n\cos\big(n(\theta-\theta')\big)$ es un kernel, por ser suma finita de kernels. Por (P2), $g(t) = a_0 + \sum_{n\geq 1} a_n\cos(nt)$, es decir, $S_M(\theta,\theta') \to g(\theta-\theta') = k(\theta,\theta')$ en cada punto. Así, k es el límite puntual de una sucesión de kernels y, por (P1), es un kernel. □

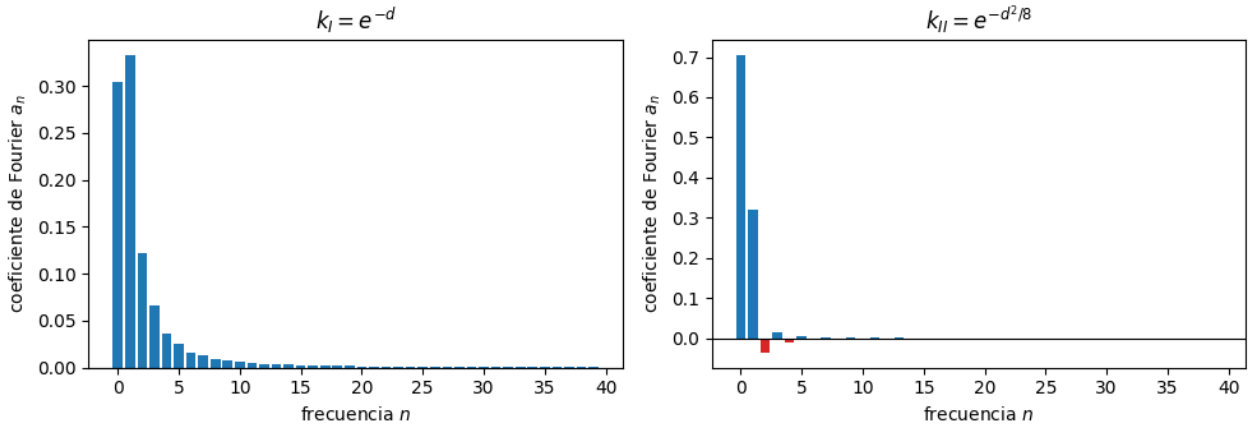
(d) Tus dos candidatos

Con $a=5$ y $b=3$, los candidatos son $k_I(\theta,\theta') = e^{-d}$ y $k_{II}(\theta,\theta') = e^{-d^2/8}$, con $d = d(\theta,\theta')$. Para aplicar (P2) hay que escribir cada uno como $g(\theta-\theta')$. Si $t = \theta-\theta' \in [0,\pi]$, los dos caminos entre los puntos miden t y $2\pi - t$, y el más corto es t, así que $d = t$. Por lo tanto $g_I(t) = e^{-|t|}$ y $g_{II}(t) = e^{-t^2/8}$ en $[-\pi,\pi]$, extendidas con periodo 2π. Ambas son continuas, pares y de periodo 2π, porque d es la distancia de $\theta-\theta'$ al múltiplo de 2π más cercano. Los coeficientes solo necesitan g en $[0,\pi]$, donde $g_I(t) = e^{-t}$ y $g_{II}(t) = e^{-t^2/8}$.

Calculé los coeficientes

$$a_0 = \frac{1}{\pi}\int_0^\pi g(t)\,dt, \qquad a_n = \frac{2}{\pi}\int_0^\pi g(t)\cos(nt)\,dt$$

por integración numérica (`scipy.integrate.quad`). La figura muestra $a_0, \ldots, a_{39}$ de cada candidato (barras azules: coeficientes positivos; rojas: negativos), y la tabla resume los primeros.



n	0	1	2	3	4	5	6
a_n de k_I	0.30455	0.33207	0.12182	0.06641	0.03583	0.02554	0.01646
a_n de k_{II}	0.70515	0.32015	−0.03597	0.01635	−0.00917	0.00585	−0.00406

$k_I = e^{-d}$ **sí es un kernel.** Los 40 coeficientes calculados son positivos. Para cubrir *toda* n, que es lo que pide (P2), uso la fórmula cerrada

$$a_0 = \frac{1 - e^{-\pi}}{\pi}, \qquad a_n = \frac{2}{\pi} \cdot \frac{1 - (-1)^n e^{-\pi}}{1 + n^2} \quad (n \geq 1),$$

que se comprueba derivando $F(t) = e^{-t}(n \sin nt - \cos nt)/(1 + n^2)$, cuya derivada es $e^{-t} \cos nt$, y evaluando en π y en 0. Coincide con los valores numéricos de la tabla. Como $e^{-\pi} \approx 0.043 < 1$, el numerador es positivo para toda n, así que $a_n > 0$ y, por (P2), k_I es un kernel. El mismo cálculo con $e^{-\lambda d}$, $\lambda > 0$, da $a_n = \frac{2}{\pi} \cdot \frac{\lambda(1-(-1)^n e^{-\lambda\pi})}{\lambda^2+n^2} > 0$, así que en la parte práctica puedo ajustar la escala λ sin perder la validez del kernel.

$k_{II} = e^{-d^2/8}$ **no es un kernel.** La demostración es un contraejemplo. Basta un conjunto de puntos y un vector v con $v^\top K v < 0$, porque la definición exige $v^\top K v \geq 0$ para *cualquier* conjunto finito de puntos y cualquier v. Tomo las horas 0, 6, 12 y 18, es decir $\theta = 0,\ \pi/2,\ \pi,\ 3\pi/2$. Los puntos contiguos están a distancia $\pi/2$ y los opuestos a distancia π. Con $\alpha = e^{-\pi^2/32} \approx 0.7346$ y $\beta = e^{-\pi^2/8} \approx 0.2912$,

$$K = \begin{pmatrix} 1 & \alpha & \beta & \alpha \\ \alpha & 1 & \alpha & \beta \\ \beta & \alpha & 1 & \alpha \\ \alpha & \beta & \alpha & 1 \end{pmatrix}, \qquad v = \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \end{pmatrix}.$$

Cada renglón de Kv es $1 - 2\alpha + \beta$ multiplicado por la entrada de v correspondiente, así que $Kv = \lambda v$ con $\lambda = 1 - 2\alpha + \beta \approx -0.1780$, y

$$v^\top K v = \lambda\,(v^\top v) = 4(1 - 2\alpha + \beta) \approx -0.7120 < 0.$$

Esta cuenta se verifica a mano, por lo que k_{II} no es un kernel sin necesidad de (P2). El vector v es $\cos(2\theta)$ evaluado en los cuatro puntos, que es la frecuencia del coeficiente negativo $a_2 \approx -0.0360$: (P2)

dice lo mismo (un $a_n < 0$ implica que no es kernel) y explica de dónde sale el contraejemplo. También lo comprobé con las 24 horas del día: con $\theta_j = 2\pi j/24$ y $v_j = \cos(2\theta_j)$ se obtiene $v^\top K v \approx -5.30$, y el menor valor propio de K es -0.4418.

Bitácora de decisiones

Las cifras vienen de `problema-2/problema-2.ipynb`, corrido con los datos completos. El error siempre está en bicicletas (MAE), salvo que se diga otra cosa.

1. Esquema de validación: tres bloques de 2012

Decidí. Validar con tres bloques consecutivos de 2012 (marzo–mayo, mayo–julio, julio–octubre), entrenando siempre con todo lo anterior a cada bloque.

Descarté. `TimeSeriesSplit` de scikit-learn.

Por qué. `TimeSeriesSplit` sobre la muestra completa (que mezcla 2011 y 2012) haría que los primeros pliegues entrenaran solo con 2011 y nunca vieran `yr=1`. La prueba es de octubre a diciembre de 2012, así que los bloques deben parecerse a esa situación: entrenar con buena parte de 2012 y validar con un trozo posterior.

Evidencia. Con la muestra real (3,000 horas), los tres bloques dan 2,011/2,283/2,556 horas de entrenamiento contra 272/273/444 de validación: todos tienen un tamaño de validación razonable y creciente, sin pliegues casi vacíos.

Qué pierdo. No valido con ningún bloque de invierno (enero–marzo), y la prueba sí incluye noviembre y diciembre, meses más fríos que los que vio la validación.

2. Qué hacer con `weathersit`, `atemp`, `season`, `mnth` y `yr`

Decidí. Agrupar `weathersit` 4 (tormenta) con el 3; excluir `atemp`, `season` y `mnth`; conservar `yr`.

Descarté. Dejar `weathersit` con sus 4 niveles, incluir las cinco variables del clima/calendario completas, o quitar `yr` para evitar que el modelo "memorice" el año.

Por qué. El nivel 4 de `weathersit` casi no aparece en los datos (es tormenta fuerte), así que separarlo deja muy pocos ejemplos para que el modelo aprenda algo útil de ese nivel. `atemp` es casi idéntica a `temp` (ambas son temperatura, una percibida y otra real) y agregarla solo duplica información y aumenta la dimensión del kernel RBF de `Kr1`. `season` y `mnth` son, como `hr` y `weekday`, variables circulares, y `temp` ya captura buena parte de lo que distingue una estación de otra; meterlas como números lineales repetiría el mismo error que se evita con `hr`. `yr` sí se conserva porque la prueba es completa de 2012 y ese valor aparece en el entrenamiento: no es fuga de información, es la tendencia de crecimiento que el problema pide considerar explícitamente.

Evidencia. Es una decisión de diseño, no una que se eligió comparando AUC o error de varias configuraciones; la justificación es por redundancia de variables y tamaño de muestra en cada nivel, no por una búsqueda adicional que hubiera exigido tocar la validación otra vez.

Qué pierdo. Si `atemp` o `season` aportaran algo que `temp` no captura (por ejemplo, viento helado que se sienta distinto a la temperatura real), esa señal se pierde. Y agrupar el nivel 4 de `weathersit` con el 3 trata igual a una tormenta fuerte y a una lluvia moderada, aunque probablemente afecten distinto el número de rentas.

3. Métrica y transformación del objetivo

Decidí. Usar el MAE en bicicletas como métrica de comparación, entrenando los modelos en escala `log1p` de `registered`, pero reportando siempre el error después de invertir la transformación.

Descarté. RMSE o RMSLE como métricas de reporte, así como entrenar directamente en la escala original.

Por qué. El objetivo del modelo es apoyar la planificación de la redistribución de bicicletas, por lo que resulta más útil expresar los errores en unidades reales. Además, la transformación `log1p` permite reducir la influencia de los valores elevados durante el entrenamiento, facilitando el ajuste del SVR.

Evidencia. `registered` toma valores entre 0 y 886, con una media de 153.8 y una mediana de 115. La diferencia entre ambas indica una distribución asimétrica hacia los valores altos.

Qué pierdo. El MAE no considera el nivel de demanda al evaluar los errores. Por ejemplo, un error de 20 bicicletas tiene el mismo peso tanto en una hora con 30 rentas como en una con 800. Por tanto, no refleja la magnitud relativa del error respecto a la demanda.

Declaración de uso de asistentes de inteligencia artificial

Se utilizó Claude (Anthropic) como apoyo en partes específicas de ambos problemas. Su uso se limitó a las actividades que se describen a continuación:

- **Problema 1:** obtener una guía de pasos para abordar el problema y revisar/corregir la libreta de trabajo, en particular el orden de selección de modelos, el tratamiento de códigos, la comparación de calibración, el *bootstrap* y el análisis de la intervención.
- **Problema 2:** obtener una guía para la parte práctica y corregir errores de código; revisar la libreta en cuanto al orden de selección de modelos y el tratamiento de códigos; y diagnosticar, a partir de resultados de ejecuciones propias, el comportamiento de k_{II} en la SVM.