Reconocimiento de Patrones. Examen intermedio C

Problema 1. Equidad imposible: parte teórica, bitácora de decisiones y memorándum

Nombre	NOMBRE POR CONFIRMAR
Expediente	222214735
Parámetros	$a = 5$, $b = 3$, semilla = 222214735

Parte teórica

En cada inciso, las probabilidades se calculan dentro de un grupo g, salvo que se indique otra cosa. Supongo que $0 < p < 1$: en el grupo hay clientes que pagan y clientes que no pagan.

(a) Una identidad

Supongo además que PPV > 0, para que la división entre PPV tenga sentido. La regla del producto dice que $\mathbb{P}(C, D) = \mathbb{P}(C \mid D)\,\mathbb{P}(D)$ para eventos C y D con $\mathbb{P}(D) > 0$, y la aplico en los dos órdenes posibles.

Primero escribo la probabilidad de un falso positivo. Condicionando en $Y = 0$ se obtiene FPR, y condicionando en $\hat{Y} = 1$ se obtiene el complemento de PPV, porque $\mathbb{P}(Y = 0 \mid \hat{Y} = 1) = 1 - \text{PPV}$ (el complemento se aplica al evento de la izquierda de la barra, con la condición fija):

$$\mathbb{P}(\hat{Y} = 1, Y = 0) = \mathbb{P}(\hat{Y} = 1 \mid Y = 0)\,\mathbb{P}(Y = 0) = \text{FPR}\,(1-p), \qquad \mathbb{P}(\hat{Y} = 1, Y = 0) = \mathbb{P}(Y = 0 \mid \hat{Y} = 1)\,\mathbb{P}(\hat{Y} = 1) = \tag{1}$$

Hago lo mismo con un verdadero positivo. Como $\mathbb{P}(\hat{Y} = 1 \mid Y = 1) = 1 - \mathbb{P}(\hat{Y} = 0 \mid Y = 1) = 1 - \text{FNR}$,

$$\mathbb{P}(\hat{Y} = 1, Y = 1) = (1 - \text{FNR})\,p, \qquad \mathbb{P}(\hat{Y} = 1, Y = 1) = \text{PPV}\,\mathbb{P}(\hat{Y} = 1). \tag{2}$$

De la segunda igualdad de (2) despejo $\mathbb{P}(\hat{Y} = 1) = (1-\text{FNR})\,p/\text{PPV}$. Al sustituirlo en la segunda igualdad de (1) y compararla con la primera queda

$$\text{FPR}\,(1 - p) = (1 - \text{PPV})\,\frac{(1 - \text{FNR})\,p}{\text{PPV}}. \tag{3}$$

Como $1 - p > 0$, puedo dividir entre $1 - p$, y al reordenar los factores obtengo la identidad:

$$\text{FPR} = \frac{p}{1-p} \cdot \frac{1 - \text{PPV}}{\text{PPV}} \cdot (1 - \text{FNR}). \tag{4}$$

■

(b) La imposibilidad

Cálculos. Con PPV $= 0.5$, el factor $(1 - \text{PPV})/\text{PPV}$ vale 1. Con FNR $= 0.3$, la identidad (4) da

$$\text{FPR}_A = \frac{0.30}{0.70} \cdot 1 \cdot 0.7 = 0.30, \qquad \text{FPR}_B = \frac{0.20}{0.80} \cdot 1 \cdot 0.7 = 0.175.$$

Para que los dos grupos tengan la misma FNR y la misma FPR, mantengo el grupo A como está y busco $\text{PPV}_B = x$ tal que $\text{FPR}_B = 0.30$ con FNR $= 0.3$:

$$0.30 = \frac{0.20}{0.80} \cdot \frac{1-x}{x} \cdot 0.7 = 0.175\,\frac{1-x}{x} \implies \frac{1-x}{x} = \frac{12}{7} \implies 7(1-x) = 12x \implies x = \frac{7}{19} \approx 0.368.$$

Los errores se igualan solo si la PPV deja de ser igual: 0.5 en A y cerca de 0.368 en B.

Proposición. *Sean $p_A \neq p_B$, con ambas en $(0,1)$. Si un clasificador tiene $0 < \text{PPV} < 1$ en los dos grupos, es decir, comete falsos positivos y también acierta algunos rechazos, entonces no puede tener a la vez la misma* PPV*, la misma* FPR *y la misma* FNR *en los dos grupos.*

Demostración. Supongamos que sí tiene las tres iguales y llamemos PPV, FPR y FNR a esos valores comunes. Como $\text{FPR}_A = \text{FPR}_B$, al aplicar (4) en cada grupo se obtiene

$$\frac{p_A}{1-p_A} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot (1 - \text{FNR}) = \frac{p_B}{1-p_B} \cdot \frac{1-\text{PPV}}{\text{PPV}} \cdot (1 - \text{FNR}).$$

Los factores $\frac{1-\text{PPV}}{\text{PPV}}$ y $1 - \text{FNR}$ aparecen en los dos lados y son distintos de cero, así que puedo cancelarlos:

- $\frac{1-\text{PPV}}{\text{PPV}} > 0$, porque $0 < \text{PPV} < 1$.
- $1-\text{FNR} > 0$. En efecto, $\text{PPV} > 0$ implica $\mathbb{P}(\hat{Y} = 1, Y = 1) > 0$, y por (2) se tiene $(1-\text{FNR})\,p > 0$, de modo que $\text{FNR} < 1$.

Queda

$$\frac{p_A}{1-p_A} = \frac{p_B}{1-p_B}.$$

Como $1 - p_A > 0$ y $1 - p_B > 0$, multiplico en cruz:

$$p_A(1-p_B) = p_B(1-p_A) \implies p_A - p_A p_B = p_B - p_A p_B \implies p_A = p_B.$$

Esto contradice la hipótesis $p_A \neq p_B$. Por lo tanto, las tres métricas no pueden coincidir a la vez. □

Clasificador perfecto. Si el clasificador es perfecto, $\text{FPR} = \text{FNR} = 0$ y todos los rechazados son incumplidos, así que $\text{PPV} = 1$ en los dos grupos. Entonces $1 - \text{PPV} = 0$ y la identidad se reduce a $0 = 0$ para cualquier p. Las tres métricas coinciden aunque $p_A \neq p_B$, de modo que la imposibilidad no aplica.

Observación sobre el enunciado. La condición exacta de la demostración es $0 < \text{PPV} < 1$. Hay tres casos extremos que no son perfectos y quedan fuera de ella:

- **Sin falsos positivos:** si solo se rechaza a incumplidos y $\text{FNR} = 0.5$ en los dos grupos, entonces $\text{PPV} = 1$, $\text{FPR} = 0$ y las tres métricas coinciden.
- **Todos los rechazos son errores:** si solo se rechaza a quienes sí pagan, entonces $\text{PPV} = 0$ y $\text{FNR} = 1$, y la FPR puede ser igual. Aquí la identidad no aplica porque habría que dividir entre cero.
- **Nunca se rechaza:** la PPV no está definida.

Ninguno de estos casos sirve como regla de crédito, así que el resultado sigue valiendo para cualquier clasificador útil: si comete falsos positivos y acierta algunos rechazos, no puede igualar las tres métricas.

(c) Calibrado no quiere decir parejo

El promedio es la tasa. Como Y solo vale 0 o 1, $p_g = \mathbb{P}(Y = 1 \mid G = g) = \mathbb{E}[Y \mid G = g]$. Por (P1), condicionando todo a $G = g$,

$$p_g = \mathbb{E}\big[\, \mathbb{E}[Y \mid S, G = g] \;\big|\; G = g \big].$$

Por (P2), $\mathbb{E}[Y \mid S = s, G = g] = \mathbb{P}(Y = 1 \mid S = s, G = g) = s$ para todo s. Es decir, la esperanza interior es la propia variable S. Por lo tanto, $p_g = \mathbb{E}[S \mid G = g]$. ■

El ejemplo. Por el resultado anterior,

$$p_A = 0.6(0.2) + 0.4(0.8) = 0.44, \qquad p_B = 0.9(0.2) + 0.1(0.8) = 0.26.$$

Por calibración, de quienes tienen puntaje 0.8 no paga el 80 %, y de quienes tienen puntaje 0.2 no paga el 20 %. Multiplicando esas proporciones por el tamaño de cada puntaje (regla del producto) se obtienen las probabilidades conjuntas:

Grupo	$\mathbb{P}(S{=}0.8, Y{=}0)$	$\mathbb{P}(S{=}0.8, Y{=}1)$	$\mathbb{P}(S{=}0.2, Y{=}0)$	$\mathbb{P}(S{=}0.2, Y{=}1)$
A	0.08	0.32	0.48	0.12
B	0.02	0.08	0.72	0.18

Rechazar a quien tiene puntaje 0.8 significa que $\hat{Y} = 1$ equivale a $S = 0.8$. La FPR es la parte rechazada entre quienes pagan, y la FNR es la parte aceptada entre quienes no pagan:

$$\mathrm{FPR}_A = \frac{0.08}{0.56} = \frac{1}{7} \approx 0.143, \quad \mathrm{FNR}_A = \frac{0.12}{0.44} = \frac{3}{11} \approx 0.273, \quad \mathrm{FPR}_B = \frac{0.02}{0.74} = \frac{1}{37} \approx 0.027, \quad \mathrm{FNR}_B = \frac{0.18}{0.26} = \frac{9}{13} \approx$$

Además, $\mathrm{PPV}_A = \frac{0.32}{0.40} = 0.8$ y $\mathrm{PPV}_B = \frac{0.08}{0.10} = 0.8$.

¿Quién sale más perjudicado? Si importa la FPR, sale peor el grupo A: un cliente cumplido de A tiene más de cinco veces la probabilidad de ser rechazado que uno de B. Si importa la FNR, sale peor el grupo B: se escapa el 69 % de sus incumplidos, contra el 27 % en A. Ese error lo paga sobre todo el banco, aunque también afecta a un cliente que recibe un crédito que no podrá pagar.

El puntaje está calibrado y $\mathrm{PPV} = 0.8$ en los dos grupos. Aun así, las tasas de error son muy distintas.

(d) El umbral del banco

Por calibración, un cliente con puntaje s no paga con probabilidad s y paga con probabilidad $1 - s$. Supongo que $G, L > 0$ y que no dar el crédito deja una ganancia de 0 (hipótesis que el enunciado no escribe y que se necesita para comparar las dos acciones). La ganancia esperada de darle el crédito es

$$(1 - s)\, G + s\, (-L) = G - (G + L)\, s.$$

Por lo tanto, conviene darlo si y solo si $G - (G + L)s > 0$. Como $G + L > 0$, esto equivale a

$$s < \frac{G}{G + L}.$$

Mi caso. Como $b = 3$, se tiene b mód $3 = 0$ y $L = 3G$. Entonces el umbral es

$$t = \frac{G}{G + 3G} = \frac{1}{4} = 0.25.$$

Por qué el mismo umbral es óptimo para todos. Sea $d_i \in \{0, 1\}$ la decisión para el cliente i, donde 1 significa dar el crédito. Por linealidad de la esperanza, la ganancia esperada total es

$$\sum_i d_i \big[G - (G + L)\, s_i\big].$$

La calibración en cada grupo garantiza que s_i es la probabilidad de no pagar sin importar el grupo, y por eso la expresión es la misma para todos. Cada término depende solo de la decisión de ese cliente, así que la suma se maximiza término por término: $d_i = 1$ si $s_i < G/(G + L)$ y $d_i = 0$ si $s_i > G/(G + L)$. Esta regla no depende del grupo. Un umbral distinto para algún grupo aceptaría clientes con ganancia esperada negativa o rechazaría clientes con ganancia esperada positiva, y no podría superarla.

Por qué eso da tasas de error distintas. Con un solo umbral t, el rechazo equivale a $S \geq t$ en los dos grupos. Pero por el inciso (c), $p_g = \mathbb{E}[S \mid G = g]$: si los grupos tienen tasas distintas, sus puntajes se distribuyen distinto. Por el inciso (b), si $p_A \neq p_B$, el clasificador no puede tener iguales PPV, FPR y FNR a la vez, salvo en los casos extremos ya descritos. Al menos una debe diferir.

Además, la calibración da $\mathrm{PPV}_g = \mathbb{E}[S \mid S \geq t, G = g]$, que no fuerza la igualdad de los errores: en el ejemplo de (c), la PPV es igual y las diferencias aparecen en FPR y FNR. Maximizar la ganancia no iguala los errores, y por eso igualarlos tiene un costo para el banco.

(e) ¿Qué es justo aquí?

Mi decisión. Conservo la calibración como propiedad del puntaje, para que un mismo número signifique el mismo riesgo en los dos grupos. Pero el criterio de equidad para la decisión de crédito es la igualdad de FPR.

Quién paga cada error. Un falso positivo lo paga una persona que sí iba a pagar: pierde el crédito sin haber hecho nada malo y no tiene forma de demostrarlo. Un falso negativo lo paga sobre todo el banco, que pierde L, aunque también perjudica a quien recibe una deuda que no puede pagar. El banco ya se protege de ese segundo error, porque en mi caso le cuesta tres veces lo que gana con un buen cliente. Por eso su umbral es tan bajo como 0.25. Nadie protege al cliente cumplido en esa cuenta, y esa es la queja del problema.

Por qué no las otras definiciones.

- **Paridad demográfica:** pide la misma tasa de rechazo aunque el riesgo sea distinto. Por (c), $E[S \mid G = g] = p_g$, así que los grupos tienen distinta distribución de riesgo. Con $t = 0.25$, A rechaza al 40 % y B al 10 %. Para igualar las tasas habría que rechazar a clientes de B con $S = 0.2$, cuya ganancia esperada de aprobarlos es positiva, o aprobar a clientes de A con $S = 0.8$, cuya ganancia esperada es negativa. Es decir, se decidiría con criterios que no corresponden al riesgo de cada persona.
- **Paridad predictiva y calibración:** son el argumento del banco, y no responden a la queja. El ejemplo de (c) cumple las dos y aun así la FPR de A es más de cinco veces la de B.

- **Misma** FPR **y misma** FNR**:** es más exigente y, por el inciso (b), también sacrifica la PPV. No la exijo porque el daño de la FNR recae principalmente en el banco. Reconozco que no controlo la FNR, que quedará desigual entre grupos, y que una FNR alta también puede perjudicar al cliente que se sobreendeuda.

¿Son aceptables los umbrales distintos? Sí, con condiciones. Por el inciso (d), el umbral común es el óptimo para el banco, y como las distribuciones de puntaje difieren entre grupos, igualar la FPR exige umbrales distintos por grupo. Entonces dos personas con el mismo puntaje pueden recibir decisiones distintas. Eso tiene un costo real: renuncio a tratar igual a quienes tienen el mismo riesgo estimado, y el corte es abrupto entre alguien de 24 años y alguien de 25. Lo acepto porque lo que quiero repartir de forma pareja es la carga sobre los clientes cumplidos. Como atenuante, la edad no es un atributo fijo, pues todas las personas pasan por ese grupo, aunque reconozco que la decisión se toma una sola vez y un joven rechazado hoy no se compensa con lo que le ocurra después. Mi condición es que sea una política explícita, revisada y que respete la ley aplicable, no un ajuste oculto.

¿Debe el modelo usar el atributo como entrada? En mi caso, sí. Quitarlo no cumple por sí mismo ninguna de estas definiciones: la imposibilidad del inciso (b) depende de las tasas de cada grupo, no de lo que vio el modelo, y otras variables pueden contener el mismo dato. Además, aplicar umbrales por grupo exige conocer el grupo. Prefiero que el atributo sea visible y que su efecto se pueda medir. Lo que pierdo es que el modelo usa la edad directamente, lo que puede ser difícil de defender ante clientes o reguladores. La parte práctica pone a prueba esta decisión en el inciso (e), y la bitácora reporta el resultado.

Declaración de uso de asistentes de IA

Usé Claude (Anthropic) para lo siguiente:

- Obtener una guía de pasos para el Problema.
- Revisar y corregir la libreta: orden de la selección de modelos, tratamiento de códigos, comparación de calibración, *bootstrap* y análisis de la intervención.