Reconocimiento de Patrones. Examen intermedio C

Problema 2. Las 23:00 y la 01:00: parte teórica

Nombre Rogelio Peralta Morales
Expediente 222214735
Parámetros $a = 5$, $b = 3$, semilla $= 222214735$

(a) Dos maneras de medir

Las horas. Las 23:00 y las 01:00 corresponden a $\theta = 23\pi/12$ y $\theta' = \pi/12$. Entonces $|\theta - \theta'| = 11\pi/6$ y $2\pi - |\theta - \theta'| = \pi/6$, así que $d = \pi/6 \approx 0.524$. Ese arco equivale a 2 horas, mientras que la diferencia de los números es 22.

Los días. En los datos, `weekday` vale 6 el sábado y 1 el lunes. Con $P = 7$ se tiene $\theta = 12\pi/7$ y $\theta' = 2\pi/7$, de modo que $|\theta - \theta'| = 10\pi/7$ y $2\pi - |\theta - \theta'| = 4\pi/7$. Por lo tanto, $d = 4\pi/7 \approx 1.795$, que equivale a 2 días, mientras que la diferencia de los números es 5.

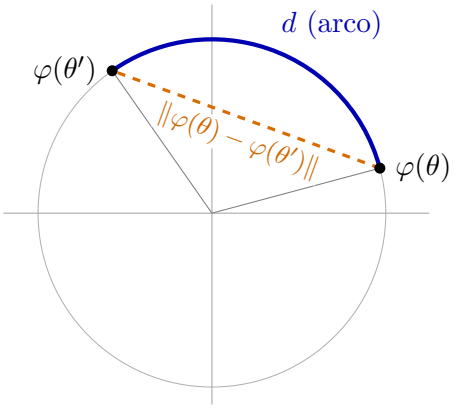
La identidad. Desarrollamos el cuadrado de la norma y usamos $\cos^2 x + \sin^2 x = 1$ en cada punto:

$$\begin{aligned}\|\varphi(\theta) - \varphi(\theta')\|^2 &= (\cos\theta - \cos\theta')^2 + (\sin\theta - \sin\theta')^2 \\ &= 2 - 2(\cos\theta\cos\theta' + \sin\theta\sin\theta') = 2 - 2\cos(\theta - \theta').\end{aligned}$$

La última igualdad es la fórmula del coseno de una diferencia. Además, d es igual a $|\theta - \theta'|$ o a $2\pi - |\theta - \theta'|$. Como el coseno es par y tiene periodo 2π, en ambos casos $\cos d = \cos(\theta - \theta')$, y queda

$$\|\varphi(\theta) - \varphi(\theta')\|^2 = 2 - 2\cos(\theta - \theta') = 2 - 2\cos d(\theta, \theta').$$

El dibujo. La figura muestra las dos medidas entre los mismos puntos: el arco d recorre el círculo y la cuerda lo cruza en línea recta.



Por qué ordenan igual. Usando $1 - \cos d = 2\sin^2(d/2)$ en la identidad, y como $\sin(d/2) \geq 0$ para $d \in [0, \pi]$, la cuerda mide

$$\|\varphi(\theta) - \varphi(\theta')\| = 2\sin(d/2).$$

La función $x \mapsto 2\sin(x/2)$ es estrictamente creciente en $[0, \pi]$, porque su derivada $\cos(x/2)$ es positiva en $[0, \pi)$. Por lo tanto, si un par tiene menor arco que otro, también tiene menor cuerda, y al revés. Las dos medidas ordenan igual a los pares, aunque no son proporcionales: casi coinciden para puntos cercanos, y en puntos opuestos el arco mide π y la cuerda 2.

(b) El seno y el coseno, otra vez

Usar $\varphi(\theta)$ con un kernel gaussiano significa usar $\exp(-\|\varphi(\theta) - \varphi(\theta')\|^2/2\sigma^2)$. Por el inciso (a),

$$\exp\left(-\frac{2 - 2\cos(\theta - \theta')}{2\sigma^2}\right) = e^{-1/\sigma^2} \exp\left(\frac{\cos(\theta - \theta')}{\sigma^2}\right).$$

Es decir, la receta equivale a k_κ con $\boxed{\kappa = 1/\sigma^2}$, multiplicado por la constante $e^{-\kappa}$. Multiplicar por una constante positiva no altera el problema de ser kernel, por (P1).

El coseno es un kernel porque tiene función de características φ:

$$\varphi(\theta)^\top \varphi(\theta') = \cos\theta\cos\theta' + \sin\theta\sin\theta' = \cos(\theta - \theta').$$

Para k_κ, escribimos la serie de Taylor de la exponencial:

$$k_\kappa(\theta, \theta') = \sum_{m=0}^{\infty} \frac{\kappa^m}{m!} \cos^m(\theta - \theta').$$

Cada potencia $\cos^m(\theta - \theta')$ con $m \geq 1$ es un kernel, porque es un producto de kernels. El término $m = 0$ es la constante 1, que es un kernel con función de características $\phi(\theta) = 1$. Cada coeficiente $\kappa^m/m!$ es positivo si $\kappa > 0$, así que cada suma parcial es una suma de kernels multiplicados por constantes positivas y, por (P1), es un kernel. Finalmente, la serie converge en cada punto y k_κ es su límite puntual, de modo que también es un kernel por (P1).

(c) Por qué funciona el criterio de Fourier

Supongamos que $a_n \geq 0$ para toda $n \geq 0$. La sugerencia es la identidad $\cos(n\theta - n\theta') = \cos n\theta \cos n\theta' + \sin n\theta \sin n\theta'$. Esto dice que el término n-ésimo es un producto punto. Para $n \geq 1$ definimos

$$\phi_n(\theta) = \sqrt{a_n}\,(\cos n\theta,\ \sin n\theta).$$

Entonces

$$\phi_n(\theta)^\top \phi_n(\theta') = a_n(\cos n\theta \cos n\theta' + \sin n\theta \sin n\theta') = a_n \cos(n(\theta - \theta')).$$

La raíz existe precisamente porque $a_n \geq 0$, así que cada término $a_n \cos(n(\theta - \theta'))$ es un kernel. El término constante a_0 también lo es, con $\phi_0(\theta) = \sqrt{a_0}$.

Por (P1), cada suma parcial $S_M(\theta, \theta') = a_0 + \sum_{n=1}^{M} a_n \cos(n(\theta - \theta'))$ es un kernel, por ser suma finita de kernels. Por (P2), $g(t) = a_0 + \sum_{n\geq 1} a_n \cos(nt)$, es decir, $S_M(\theta, \theta') \to g(\theta - \theta') = k(\theta, \theta')$ en cada punto. Así, k es el límite puntual de una sucesión de kernels y, por (P1), es un kernel. $\square$

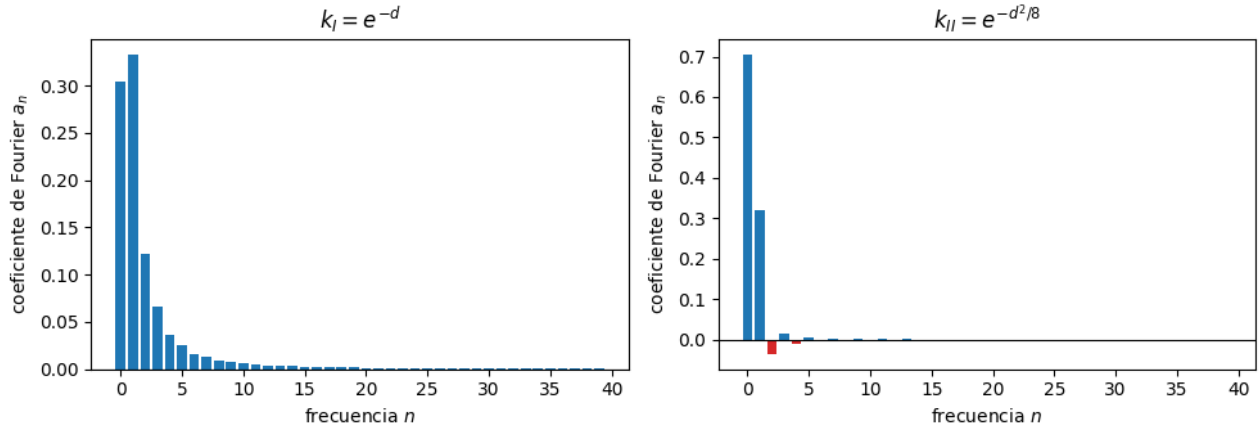
(d) Tus dos candidatos

Con $a = 5$ y $b = 3$, los candidatos son $k_I(\theta, \theta') = e^{-d}$ y $k_{II}(\theta, \theta') = e^{-d^2/8}$, con $d = d(\theta, \theta')$. Para aplicar (P2) hay que escribir cada uno como $g(\theta - \theta')$. Si $t = \theta - \theta' \in [0, \pi]$, los dos caminos entre los puntos miden t y $2\pi - t$, y el más corto es t, así que $d = t$. Por lo tanto $g_I(t) = e^{-|t|}$ y $g_{II}(t) = e^{-t^2/8}$ en $[-\pi, \pi]$, extendidas con periodo 2π. Ambas son continuas, pares y de periodo 2π, porque d es la distancia de $\theta - \theta'$ al múltiplo de 2π más cercano. Los coeficientes solo necesitan g en $[0, \pi]$, donde $g_I(t) = e^{-t}$ y $g_{II}(t) = e^{-t^2/8}$.

Calculé los coeficientes

$$a_0 = \frac{1}{\pi}\int_0^{\pi} g(t)\,dt, \qquad a_n = \frac{2}{\pi}\int_0^{\pi} g(t)\cos(nt)\,dt$$

por integración numérica (`scipy.integrate.quad`). La figura muestra $a_0, \ldots, a_{39}$ de cada candidato (barras azules: coeficientes positivos; rojas: negativos), y la tabla resume los primeros.



n	0	1	2	3	4	5	6
a_n de k_I	0.30455	0.33207	0.12182	0.06641	0.03583	0.02554	0.01646
a_n de k_{II}	0.70515	0.32015	−0.03597	0.01635	−0.00917	0.00585	−0.00406

$k_I = e^{-d}$ **sí es un kernel.** Los 40 coeficientes calculados son positivos. Para cubrir *toda* n, que es lo que pide (P2), uso la fórmula cerrada

$$a_0 = \frac{1 - e^{-\pi}}{\pi}, \qquad a_n = \frac{2}{\pi}\cdot\frac{1 - (-1)^n e^{-\pi}}{1 + n^2} \quad (n \geq 1),$$

que se comprueba derivando $F(t) = e^{-t}(n\sin nt - \cos nt)/(1+n^2)$, cuya derivada es $e^{-t}\cos nt$, y evaluando en π y en 0. Coincide con los valores numéricos de la tabla. Como $e^{-\pi} \approx 0.043 < 1$, el numerador es positivo para toda n, así que $a_n > 0$ y, por (P2), k_I es un kernel. El mismo cálculo con $e^{-\lambda d}$, $\lambda > 0$, da $a_n = \frac{2}{\pi}\cdot\frac{\lambda(1-(-1)^n e^{-\lambda\pi})}{\lambda^2+n^2} > 0$, así que en la parte práctica puedo ajustar la escala λ sin perder la validez del kernel.

$k_{II} = e^{-d^2/8}$ **no es un kernel.** La demostración es un contraejemplo. Basta un conjunto de puntos y un vector v con $v^\top K v < 0$, porque la definición exige $v^\top K v \geq 0$ para *cualquier* conjunto finito de puntos y cualquier v. Tomo las horas 0, 6, 12 y 18, es decir $\theta = 0,\ \pi/2,\ \pi,\ 3\pi/2$. Los puntos contiguos están a distancia $\pi/2$ y los opuestos a distancia π. Con $\alpha = e^{-\pi^2/32} \approx 0.7346$ y $\beta = e^{-\pi^2/8} \approx 0.2912$,

$$K = \begin{pmatrix} 1 & \alpha & \beta & \alpha \\ \alpha & 1 & \alpha & \beta \\ \beta & \alpha & 1 & \alpha \\ \alpha & \beta & \alpha & 1 \end{pmatrix}, \qquad v = \begin{pmatrix} 1 \\ -1 \\ 1 \\ -1 \end{pmatrix}.$$

Cada renglón de Kv es $1 - 2\alpha + \beta$ multiplicado por la entrada de v correspondiente, así que $Kv = \lambda v$ con $\lambda = 1 - 2\alpha + \beta \approx -0.1780$, y

$$v^\top K v = \lambda\,(v^\top v) = 4(1 - 2\alpha + \beta) \approx -0.7120 < 0.$$

Esta cuenta se verifica a mano, por lo que k_{II} no es un kernel sin necesidad de (P2). El vector v es $\cos(2\theta)$ evaluado en los cuatro puntos, que es la frecuencia del coeficiente negativo $a_2 \approx -0.0360$: (P2) dice lo mismo (un $a_n < 0$ implica que no es kernel) y explica de dónde sale el contraejemplo. También lo comprobé con las 24 horas del día: con $\theta_j = 2\pi j/24$ y $v_j = \cos(2\theta_j)$ se obtiene $v^\top K v \approx -5.30$, y el menor valor propio de K es -0.4418.

Bitácora de decisiones

Las cifras vienen de `problema-2/problema-2.ipynb`, corrido con los datos completos. El error siempre está en bicicletas (MAE), salvo que se diga otra cosa.

1. Esquema de validación: tres bloques de 2012

Decidí. Validar con tres bloques consecutivos de 2012 (marzo–mayo, mayo–julio, julio–octubre), entrenando siempre con todo lo anterior a cada bloque.

Descarté. `TimeSeriesSplit` de scikit-learn.

Por qué. `TimeSeriesSplit` sobre la muestra completa (que mezcla 2011 y 2012) haría que los primeros pliegues entrenaran solo con 2011 y nunca vieran `yr=1`. La prueba es de octubre a diciembre de 2012, así que los bloques deben parecerse a esa situación: entrenar con buena parte de 2012 y validar con un trozo posterior.

Evidencia. Con la muestra real (3,000 horas), los tres bloques dan 2,011/2,283/2,556 horas de entrenamiento contra 272/273/444 de validación: todos tienen un tamaño de validación razonable y creciente, sin pliegues casi vacíos.

Qué pierdo. No valido con ningún bloque de invierno (enero–marzo), y la prueba sí incluye noviembre y diciembre, meses más fríos que los que vio la validación.

2. Qué hacer con `weathersit`, `atemp`, `season`, `mnth` y `yr`

Decidí. Agrupar `weathersit` 4 (tormenta) con el 3; excluir `atemp`, `season` y `mnth`; conservar `yr`.

Descarté. Dejar `weathersit` con sus 4 niveles, incluir las cinco variables del clima/calendario completas, o quitar `yr` para evitar que el modelo "memorice" el año.

Por qué. El nivel 4 de `weathersit` casi no aparece en los datos (es tormenta fuerte), así que separarlo deja muy pocos ejemplos para que el modelo aprenda algo útil de ese nivel. `atemp` es casi idéntica a `temp` (ambas son temperatura, una percibida y otra real) y agregarla solo duplica información y aumenta la dimensión del kernel RBF de `Kr1`. `season` y `mnth` son, como `hr` y `weekday`, variables circulares, y `temp` ya captura buena parte de lo que distingue una estación de otra; meterlas como números lineales repetiría el mismo error que se evita con `hr`. `yr` sí se conserva porque la prueba es completa de 2012 y ese valor aparece en el entrenamiento: no es fuga de información, es la tendencia de crecimiento que el problema pide considerar explícitamente.

Evidencia. Es una decisión de diseño, no una que se eligió comparando AUC o error de varias configuraciones; la justificación es por redundancia de variables y tamaño de muestra en cada nivel, no por una búsqueda adicional que hubiera exigido tocar la validación otra vez.

Qué pierdo. Si `atemp` o `season` aportaran algo que `temp` no captura (por ejemplo, viento helado que se sienta distinto a la temperatura real), esa señal se pierde. Y agrupar el nivel 4 de `weathersit` con el 3 trata igual a una tormenta fuerte y a una lluvia moderada, aunque probablemente afecten distinto el número de rentas.

3. Métrica y transformación del objetivo

Decidí. Usar el MAE en bicicletas como métrica de comparación, entrenando los modelos en escala `log1p` de `registered`, pero reportando siempre el error después de invertir la transformación.

Descarté. RMSE o RMSLE como métricas de reporte, así como entrenar directamente en la escala original.

Por qué. El objetivo del modelo es apoyar la planificación de la redistribución de bicicletas, por lo que resulta más útil expresar los errores en unidades reales. Además, la transformación `log1p` permite reducir la influencia de los valores elevados durante el entrenamiento, facilitando el ajuste del SVR.

Evidencia. `registered` toma valores entre 0 y 886, con una media de 153.8 y una mediana de 115. La diferencia entre ambas indica una distribución asimétrica hacia los valores altos.

Qué pierdo. El MAE no considera el nivel de demanda al evaluar los errores. Por ejemplo, un error de 20 bicicletas tiene el mismo peso tanto en una hora con 30 rentas como en una con 800. Por tanto, no refleja la magnitud relativa del error respecto a la demanda.

Declaración de uso de asistentes de IA

Usé Claude (Anthropic) para lo siguiente:

- Obtener una guía de pasos para la parte práctica del Problema y corregir errores de código.
- Revisar y corregir la libreta: orden de la selección de modelos, tratamiento de códigos.
- Diagnosticar, en varias rondas con resultados reales de mi ejecución, por qué k_{II} produce resultados sin sentido en la SVM.